

El agregado favorece a la variante; los segmentos no

Resultados descriptivos

Control activa 1.380 de 2.000 cuentas: 69%. Variante activa 1.500 de 2.000: 75%. El agregado muestra +6 puntos porcentuales para la variante.

La lectura cambia al separar dispositivo. En escritorio, control logra $720/800 = 90\%$ y variante $1.020/1.200 = 85\%$, por lo que la variante queda 5 puntos abajo. En móvil, control logra $660/1.200 = 55\%$ y variante $480/800 = 60\%$, de modo que la variante queda 5 puntos arriba.

Por qué cambia la historia

Las versiones no contienen la misma mezcla: 60% de la variante está en escritorio, el segmento con tasas más altas en ambas versiones; en control, escritorio representa 40%. Por eso el 75% global combina rendimiento y composición. No es correcto leer los +6 puntos como una mejora uniforme.

Además, la versión dependió de horario y día. Si mañana laboral se relaciona con tipo de usuario o disposición a completar, la diferencia global o segmentada puede incluir ese patrón. Las tablas describen las cuentas observadas, pero no identifican un efecto causal.

Decisión

No lanzaría la variante a toda la base. Mantendría control en escritorio y consideraría un piloto móvil solo como hipótesis, no como efecto confirmado. El signo opuesto por dispositivo hace razonable priorizar interacción versión-dispositivo.

El siguiente paso sería asignar aleatoriamente dentro de cada dispositivo y bloques de horario, manteniendo el denominador de cuentas asignadas. Así cada versión tendría composiciones comparables y el horario no quedaría casi unido a una versión. También reportaría intervalos de incertidumbre, pero primero corregiría el diseño: más precisión no elimina un sesgo de asignación.

Descomposición del agregado

En control, el 40% de las cuentas está en escritorio y el 60% en móvil. Su tasa ponderada es $0,40 \times 90\% + 0,60 \times 55\% = 69\%$. En variante, los pesos se invierten: $0,60 \times 85\% + 0,40 \times 60\% = 75\%$. Por eso los dos porcentajes globales responden a mezclas distintas. Si aplico a ambas versiones una mezcla común de 50% escritorio y 50% móvil, las dos dan 72,5%; esa estandarización descriptiva no estima un efecto, pero muestra cuánto depende el agregado de la composición.

Los efectos por dispositivo tampoco son uniformes: -5 puntos en escritorio y +5 en móvil. Esta interacción puede ser real o puede reflejar la asignación por horario y día. El dossier dice que la versión dependió de esos factores, de modo que igualdad de tamaño total no garantiza comparabilidad dentro de cada celda ni entre usuarios.

Plan de repetición y umbral de decisión

Repetiría con asignación aleatoria dentro de cuatro bloques: escritorio/mañana, escritorio/tarde, móvil/mañana y móvil/tarde, distribuyendo ambas versiones durante los mismos días. Mantendría la unidad de cuenta y la ventana de 24 horas para no cambiar el KPI. Antes de observar resultados definiría si el producto acepta una pérdida en escritorio a cambio de una mejora móvil o si exige no perjudicar ningún segmento principal.

Reportaría tasas, conteos, diferencia absoluta e intervalo por bloque. También comprobaría pérdidas de seguimiento y errores de instrumentación. No usaría el benchmark externo porque no está autorizado. Con la evidencia actual, un rollout completo mezcla una oportunidad móvil con una señal negativa en escritorio y una asignación no aleatoria.

Qué quedaría abierto incluso después del recálculo

El dossier no aporta una regla de significancia, un costo de error ni una métrica de largo plazo. Por eso no convertiría los conteos actuales en una decisión automática mediante un umbral inventado. Las 120 activaciones adicionales describen esta muestra bajo su mezcla observada; no prueban cuántas se conservarían a 30 o 90 días ni si tendrían la misma calidad. Preguntar por retención exigiría datos que no están autorizados.

La repetición propuesta tampoco garantiza por sí sola una decisión sencilla. Si el resultado móvil volviera a ser positivo y el de escritorio negativo, el equipo tendría que aplicar el criterio definido antes de mirar los datos: segmentar el despliegue, aceptar un intercambio explícito o exigir no inferioridad en ambos grupos. Mi recomendación actual es detener el lanzamiento global porque esa regla aún no existe y porque versión, horario y dispositivo no quedaron separados.

Finalmente, conservaría una tabla de asignación y exclusiones antes del análisis. Así podría distinguir una cuenta asignada que no inició el flujo de una pérdida de instrumentación y evitaría cambiar el denominador después de ver el resultado. Este control responde a una incertidumbre del propio dossier; no supone conocer comportamiento externo de usuarios ni benchmarks del producto.